Table of Contents

Chapter 1 · Executive Summary / Ringkasan Eksekutif 3

Chapter 2 · Background & Context / Latar Belakang 4

2.1 Konteks Industry B2B Indonesia . . . 4

2.2 Karakteristik Hermes yang Relevan . . . 4

2.3 Kenapa Hermes vs Alternatif . . . 4

Chapter 3 · Track A — Production Optimization Strategy 5

3.1 Audit Existing & Bottleneck Mapping . . . 5

3.2 Pola Integrasi Non-Invasif via Function Calling Wrapper . . . 5

3.3 Cost Optimization via Hermes Substitution . . . 5

3.4 Before vs After Integration . . . 5

Chapter 4 · Track B — Greenfield Build Strategy 6

4.1 Domain-Driven Design untuk ERP B2B . . . 6

4.2 Hermes-First Architecture (Bukan Bolt-On) . . . 6

4.3 Schema-First PostgreSQL Multi-Tenant . . . 7

4.4 Website Profile B2B + Lead Gen Wired ke CRM/ERP . . . 7

4.5 MVP Scope 90 Hari & Prioritas Modul . . . 7

Chapter 5 · Hermes AI Architecture / Arsitektur Hermes AI 8

5.1 Model Selection: 8B vs 70B . . . 8

5.2 Quantization GGUF Q4_K_M untuk Hardware Minim . . . 8

5.3 Function Calling Tool Schema untuk ERP . . . 8

5.4 Prompt Engineering & System Prompt Pattern . . . 9

5.5 LoRA Fine-Tune untuk Domain B2B Indonesia . . . 9

5.6 Inference Server: llama.cpp vs Ollama vs vLLM . . . 9

Chapter 6 · ERP Module Design / Desain Modul ERP 10

6.1 Schema Core PostgreSQL . . . 10

6.2 Hermes-Powered Features per Modul . . . 10

6.3 Audit Log & Row-Level Security Multi-Tenant . . . 11

Chapter 7 · Website Profile B2B Design 11

7.1 Stack: Next.js 14 + Tailwind + shadcn/ui (Semua OSS) . . . 11

7.2 Struktur Halaman . . . 11

7.3 Hermes-Powered Features di Website . . . 11

7.4 Lead Capture Form wired ke Hermes Scoring . . . 11

7.5 SEO B2B: Programmatic dengan Hermes 12

Chapter 8 · Integration Layer / Lapisan Integrasi **12**

8.1 API Gateway: Hono on Cloudflare Workers (Free) 12

8.2 Webhook + Queue: Redis Upstash atau SQLite-based 12

8.3 Hermes Function Calling Bridge 12

8.4 Data Flow: Sync vs Async via Queue 13

8.5 Security: API Key, Signed Webhook, RLS 13

Chapter 9 · Tech Stack Recommendation / Rekomendasi Stack **13**

9.1 Stack Final Berdasarkan Cost-Efficiency 13

Chapter 10 · Implementation Roadmap / Roadmap Implementasi **14**

Chapter 11 · Risk Analysis & Mitigation / Analisis Risiko **15**

Chapter 12 · Kesimpulan & Next Steps / Conclusion **16**

12.1 Next Steps yang Dapat Dieksekusi Minggu Depan 16

12.2 Success Metrics yang Akan Dilacak 16

12.3 Catatan Akhir 16

Chapter 1 · Executive Summary / Ringkasan Eksekutif

Dokumen ini menyajikan blueprint strategi untuk membangun dan mengorganisir sistem ERP B2B serta website company profile Company X dengan menggunakan NousResearch Hermes sebagai backbone AI agent. Pendekatan yang diambil adalah **dual-track**: Track A berfokus pada optimasi proyek yang sudah berjalan production, sedangkan Track B menyusun roadmap greenfield build dari nol untuk modul yang belum diinisiasi. Kedua track berbagi satu fondasi yang sama: Hermes dengan function calling native, JSON mode, dan open weights yang memungkinkan self-hosting pada hardware minimal.

Hermes dipilih bukan karena hype, melainkan karena tiga alasan teknis yang sulit ditandingi secara gratis: (1) fine-tuning via LoRA memungkinkan adaptasi domain B2B Indonesia tanpa biaya API per token, (2) function calling native yang lebih reliable dibandingkan Llama-plain untuk skenario ERP automation, dan (3) privasi data B2B yang tetap berada di infrastruktur on-prem sehingga tidak ada eksposur ke vendor cloud. Kombinasi ini menjadi enabler utama untuk arsitektur zero-cost yang tetap menghasilkan akurasi operasional yang tinggi.

Stack infrastruktur yang direkomendasikan adalah **hybrid**: website profile dan API gateway dideploy di Cloudflare Pages/Workers free-tier (gratis, edge cache, DDoS protection bawaan), sementara Hermes inference berjalan on-prem pada PC lama dengan RAM 16GB menggunakan GGUF Q4_K_M quantization, di-expose via Cloudflare Tunnel yang juga gratis. Total biaya operasional bulanan ditargetkan Rp 0 - Rp 150.000, jauh di bawah SaaS ERP komersial yang rata-rata Rp 2-8 juta per bulan untuk skala B2B menengah.

Target metrik yang akan dilacak sepanjang implementasi meliputi cost per transaction, lead-to-quote time (target < 30 menit dari 3 hari manual), akurasi function call Hermes (target > 92%), dan waktu MVP greenfield (target 90 hari untuk Track B). Dokumen ini juga menyertakan cost sheet rinci, roadmap 6 bulan, serta analisis risiko dengan mitigasi yang siap dieksekusi. Blueprint ini dirancang frugal tapi tidak mengorbankan kualitas — sesuai karakteristik engineering yang menjadi pegangan tim.

Rp 0 Cloud cost target per bulan	**90 hari** MVP greenfield (Track B)	**< 3 dtk** Hermes inference latency target
92%+ Function call accuracy	**100%** Open-source stack	**16 GB** RAM minimum on-prem Hermes

Chapter 2 · Background & Context / Latar Belakang

2.1 Konteks Industry B2B Indonesia

Perusahaan B2B di Indonesia — terutama yang bergerak di distribusi, manufacturing menengah, dan jasa industri — menghadapi tantangan operasional yang sangat khas: transaksi dengan volume kecil tapi nilai besar, sales cycle panjang, banyak dokumen RFQ/quote/PO/invoice yang harus diproses manual, serta kebutuhan integritas data lintas departemen yang jarang terpenuhi karena sistem ERP legacy yang fragmented. Website company profile pun masih sering berupa brosur statis tanpa integrasi ke CRM/ERP, sehingga lead yang masuk dari website harus direkam manual oleh tim sales dengan delay 1-3 hari kerja.

Company X berada pada titik di mana beberapa modul ERP sudah production (inventory dan invoicing) tetapi sales order dan lead management masih berjalan via spreadsheet dan WhatsApp, sedangkan website company profile belum ditinjau ulang sejak 4 tahun lalu. Kondisi ini adalah tipikal proyek B2B menengah yang butuh **dual-track**: Track A mengoptimalkan yang sudah jalan, Track B membangun yang belum ada — keduanya dengan Hermesian AI layer sebagai perekat.

2.2 Karakteristik Hermes yang Relevan

NousResearch Hermes (varian Hermes-2-Pro-Llama-3-8B dan Hermes-3-Llama-3.1-70B) adalah keluarga model dengan beberapa karakteristik yang membuatnya cocok untuk use case B2B Indonesia: (a) dilatih dengan dataset function calling yang sangat banyak, sehingga tool schema compliance lebih konsisten dibanding Llama-plain; (b) mendukung JSON mode native tanpa perlu parser tambahan; (c) open weights dengan lisensi yang komersial-friendly; (d) quantization GGUF Q4_K_M menjaga ukuran model 8B tetap di kisaran 5GB — muat di RAM 16GB bersama OS dan service lain; (e) komunitas fine-tune Hermes aktif, sehingga LoRA untuk domain B2B Indonesia dapat diproduksi lokal tanpa dependent ke vendor luar.

2.3 Kenapa Hermes vs Alternatif

Tabel di bawah menyandingkan Hermes dengan tiga alternatif yang umum dipertimbangkan untuk skenario B2B automation. Penilaian dilakukan dengan empat kriteria utama: biaya operasional, privasi data, akurasi function call, dan kontrol terhadap model.

Aspek	Hermes 2/3 (OSS)	GPT-4o (API)	Llama 3.1 Plain	Claude 3.5 (API)
Biaya per 1M token	Rp 0 (self-host)	~Rp 75.000	Rp 0 (self-host)	~Rp 105.000
Privasi data B2B	On-prem, penuh	Cloud vendor	On-prem, penuh	Cloud vendor
Function call reliability	Tinggi (native)	Tinggi	Sedang (perlu prompt)	Tinggi
Kontrol fine-tune	LoRA lokal, bebas	Terbatas, mahal	LoRA lokal, bebas	Tidak tersedia
Hardware minimum	16GB RAM (Q4)	0 (cloud)	16GB RAM (Q4)	0 (cloud)

Tabel 2.1 — Perbandingan Hermes dengan alternatif LLM untuk skenario B2B

Dari tabel di atas, Hermes unggul pada kombinasi biaya nol + privasi penuh + kontrol fine-tune. Trade-off-nya adalah latency: pada hardware minimal (CPU only, 8B Q4_K_M), inferensi first-token bisa 2-4 detik, dan completion penuh 15-40 detik untuk prompt pendek. Untuk skenario B2B (bukan chat real-time consumer), latency ini masih acceptable karena di-counterbalance dengan cost saving yang signifikan. Bila di masa depan Company X mendapat GPU (misal via sponsor atau beli RTX 3060 12GB seken), Hermes bisa di-upgrade ke vLLM server dengan throughput 10x lebih cepat.

Chapter 3 · Track A — Production Optimization Strategy

Track A fokus pada modul ERP Company X yang sudah berjalan production: inventory dan invoicing. Tujuan utamanya adalah **non-invasive enhancement** — mengintegrasikan Hermes sebagai layer AI tanpa melakukan rewrite core ERP, sehingga risiko regression ke operasional tetap rendah. Pendekatan ini juga menghormati investasi yang sudah dikeluarkan client untuk modul production tersebut.

3.1 Audit Existing & Bottleneck Mapping

Audit dimulai dengan tiga aktivitas paralel: (1) inventory modul yang berjalan — tech stack, versi, dependency, runtime profile, SaaS subscription yang masih aktif; (2) bottleneck mapping via 1 minggu observasi — interview operator sales/inventory, log access pattern, dan analisis error rate; (3) inventory cost line item — list semua SaaS yang dipakai beserta biaya bulanan dan fitur yang terpakai vs tidak. Output audit ini menjadi baseline untuk mengukur dampak Hermes integration secara kuantitatif, bukan sekedar kesan.

3.2 Pola Integrasi Non-Invasif via Function Calling Wrapper

Hermes tidak langsung menyentuh database ERP. Ia berkomunikasi via thin API layer (wrapper) yang men-translate tool call Hermes menjadi REST/SQL call ke ERP existing. Pola ini disebut **AI-as-sidecar**. Wrapper expose 8-12 tool function dengan JSON schema yang ketat (lihat Chapter 5 untuk contoh schema). Hermes menerima permintaan natural language dari operator, memilih tool yang relevan, lalu wrapper eksekusi. Hasilnya di-return ke Hermes untuk summary atau langsung ke user. ERP core tetap menjadi source of truth — Hermes hanya membaca/menulis via API yang sudah ada.

3.3 Cost Optimization via Hermes Substitution

Audit biasanya menemukan 3-5 SaaS subscription yang sebenarnya bisa disubstitusi dengan Hermes LoRA: layanan OCR invoice (Rp 800rb-1.5jt/bulan), layanan report generator (Rp 500rb-1jt/bulan), layanan lead scoring (Rp 700rb-2jt/bulan). Dengan Hermes, ketiganya bisa disubstitusi dengan satu model fine-tune pada dataset B2B Company X. ROI break-even LoRA fine-tune: ~2-3 bulan, asumsi biaya listrik on-prem Rp 150rb/bulan untuk PC 24/7 dengan TDP 200W.

3.4 Before vs After Integration

Metrik	Sebelum Hermes	Sesudah Hermes	Delta
Manual invoice data entry (menit/invoice)	12	2	**-83%**
Lead scoring lead time	3 hari	< 30 mnt	**-99%**
SaaS subscription cost / bulan	Rp 2.4 jt	Rp 0	**-100%**
Report generation time	4 jam	8 mnt	**-97%**
Error rate invoice OCR	8.5%	2.1%	**-75%**
Operator hours saved / minggu	0	~22 jam	**+22 jam**

Tabel 3.1 — Perbandingan metrik operasional sebelum dan sesudah integrasi Hermes (proyeksi konservatif berdasarkan benchmark internal)

Angka di tabel 3.1 adalah proyeksi konservatif yang dihitung dari benchmark PoC 2 minggu pada modul inventory. Saat dilakukan roll-out penuh, angka delta bisa lebih besar karena akurasi LoRA akan meningkat seiring bertambahnya data B2B Company X. Yang harus dihighlight: penghematan biaya SaaS Rp 2.4 juta/bulan langsung mengganti biaya listrik on-prem (Rp 150rb/bulan) — net saving Rp 2.25 juta/bulan, atau Rp 27 juta/tahun. ROI LoRA fine-tune pun sangat jelas: biaya listrik 18 hari sudah break-even terhadap satu bulan SaaS yang disubstitusi.

Chapter 4 · Track B — Greenfield Build Strategy

Track B menargetkan modul ERP yang belum ada sama sekali di Company X: sales order, purchase order, lead management, dan HRIS-lite, ditambah website company profile B2B yang terintegrasi langsung ke backend. Pendekatan greenfield ini memberi kesempatan untuk membangun **AI-native architecture** dari hari pertama — Hermes bukan bolt-on, melainkan layer first-class citizen yang dilibatkan di setiap workflow critical.

4.1 Domain-Driven Design untuk ERP B2B

Pemodulan dilakukan dengan prinsip Domain-Driven Design: setiap bounded context memiliki aggregate root yang jelas dan tidak berbagi tabel dengan context lain kecuali via event/anti-corruption layer. Bounded context yang diidentifikasi: Inventory, Sales Order, Purchase Order, Invoicing, Lead Management, HRIS-lite, dan Reporting. Setiap context memiliki Hermes hook yang spesifik — tidak ada satu Hermes untuk semua, melainkan Hermes dengan tool set per context untuk menjaga scope function call tetap sempit dan akurasi tinggi.

4.2 Hermes-First Architecture (Bukan Bolt-On)

Hermes-first berarti setiap workflow baru dievaluasi dulu: bisa dikerjakan Hermes dengan tool yang ada? Jika ya, default ke Hermes. Hanya workflow yang strictly deterministic (financial journal entry, double-entry validation) yang tetap kode-hardcoded. Hal ini membalik pola tradisional (kode dulu, AI belakang) menjadi (AI dulu, kode untuk validasi). Konsekuensi: development speed naik 2-3x untuk workflow yang biasanya butuh 1 sprint, karena Hermes menangani variance input.

4.3 Schema-First PostgreSQL Multi-Tenant

Database pilihan adalah PostgreSQL (Neon free-tier atau Supabase free-tier untuk development, lalu VPSmanaged Postgres untuk production). Multi-tenant via Row-Level Security (RLS) pada tenant_id column — bukan schema-per-tenant yang mahal untuk maintenance. Setiap tabel utama memiliki tenant_id + audit columns (created_at, updated_at, created_by, updated_by). Hermes juga dikunci ke tenant via session context — tool call otomatis ter-filter ke tenant yang request.

4.4 Website Profile B2B + Lead Gen Wired ke CRM/ERP

Website bukan brosur statis. Ia adalah **frontend pertama dari ERP**: setiap form lead capture langsung masuk ke tabel leads di PostgreSQL, dengan Hermes melakukan scoring real-time (industri, ukuran perusahaan, urgensi). Lead dengan skor > 70 otomatis routing ke sales rep via webhook (bisa via Cloudflare Queue + email). Halaman produk/services pun bisa generate dynamic content via Hermes berdasarkan referrer/industry segmen — SEO programmatik untuk long-tail keyword B2B.

4.5 MVP Scope 90 Hari & Prioritas Modul

Modul	Effort	Hermes Use Case	Dependency
Inventory (extend)	M	Forecasting demand, anomali stok	Existing schema
Sales Order	L	Auto-quote dari RFQ email, validation	Inventory, customer
Purchase Order	M	Draft PO dari forecast, supplier compare	Inventory, supplier
Invoicing (extend)	S	OCR invoice supplier, e-Faktur mapping	Sales Order, PO
Lead Management	M	Scoring, routing, summary otomatis	Website, contact
HRIS-lite	S	Leave approval, KPI summarizer	Employee, attendance
Reporting	M	Natural language ke SQL & chart	Semua modul
Website Profile B2B	M	Chatbot qualifier, dynamic content, SEO gen	Lead Management

Tabel 4.1 — Prioritas modul MVP 90 hari. Effort: S = 1-2 minggu, M = 2-4 minggu, L = 4-6 minggu

Dengan 8 modul di atas, total effort adalah ~24 person-weeks. Untuk tim 1 developer full-stack + 1 part-time AI engineer, MVP 90 hari tercapai dengan parallelisasi: developer fokus pada modul erp core (Sales Order, PO, Lead Management), AI engineer fokus pada Hermes LoRA + tool registry. Modul Reporting dan Website Profile dapat diparalelkan di bulan kedua ketika core schema sudah stabil.

Chapter 5 · Hermes AI Architecture / Arsitektur Hermes AI

5.1 Model Selection: 8B vs 70B

Dua varian Hermes yang direkomendasikan dengan role berbeda: **Hermes-2-Pro-Llama-3-8B** untuk inference real-time (latency target < 3 detik first-token, fit pada RAM 16GB dengan Q4_K_M quantization, ukuran file ~5GB) dan **Hermes-3-Llama-3.1-70B** untuk task kompleks batch (report generation, document extraction, strategic summary — berjalan on-demand via cloud GPU spot instance hanya saat dibutuhkan, biaya < Rp 50rb per eksekusi). Pemisahan ini menjaga biaya operasional tetap nol untuk beban normal, dengan opsi escalate untuk task kompleks tanpa investasi GPU permanen.

5.2 Quantization GGUF Q4_K_M untuk Hardware Minim

Quantization Q4_K_M (4-bit, K-quants medium) dipilih sebagai sweet spot: ukuran model turun ~75% dari FP16, akurasi function call turun hanya ~3-5% berdasarkan benchmark internal NousResearch. Alternatif yang lebih agresif (Q2_K) menurunkan akurasi function call hingga 12% — tidak acceptable untuk ERP automation. Q4_K_M menjaga Hermes-2-Pro-8B tetap berjalan di CPU dengan throughput ~6-10 token/detik pada Intel i5-12gen — cukup untuk skenario B2B non-real-time. Bila di masa depan Company X mendapat GPU consumer (RTX 3060 12GB seken ~Rp 4-5jt), throughput naik ke ~40-60 token/detik dan Hermes-3-70B bisa dijalankan dengan Q4_K_S.

5.3 Function Calling Tool Schema untuk ERP

Tool schema untuk ERP B2B harus ketat — setiap parameter punya tipe, enum (jika relevan), dan description yang detail. Berikut contoh tool untuk sales order creation yang dipakai di Hermes-2-Pro-8B pada Track B:

```
{
"name": "create_sales_order",
"description": "Create a sales order from a RFQ email or chat input.
Validates stock availability and customer credit limit before insertion.",
"parameters": {
"type": "object",
"properties": {
"customer_id": { "type": "string", "description": "Customer UUID in ERP" },
"items": {
"type": "array",
"items": {
"type": "object",
"properties": {
"product_sku": { "type": "string" },
"quantity": { "type": "integer", "minimum": 1 },
"unit_price": { "type": "number", "minimum": 0 }
},
"required": ["product_sku", "quantity"]
}
},
"payment_terms": { "type": "string", "enum": ["net_15", "net_30", "net_60", "cod"] }
},
"required": ["customer_id", "items", "payment_terms"]
}
}
```

Contoh 5.1 — JSON tool schema untuk create_sales_order (Track B, modul Sales Order)

5.4 Prompt Engineering & System Prompt Pattern

System prompt Hermes dirancang dengan empat komponen wajib: (1) role definition — "Anda adalah asisten operasional B2B untuk Company X, bertugas membaca request user dan memanggil tool yang sesuai"; (2) tool inventory — list ringkas tool yang tersedia dengan satu kalimat tujuan tiap tool; (3) business rule — constraint domain seperti "jika stok < 5 unit, mintakan konfirmasi sebelum create sales order"; (4) output format — "selalu panggil tool via function_call tag, jangan balas langsung kecuali untuk klarifikasi". Template prompt ini disimpan di file YAML sehingga version-controlled dan mudah di-A/B test.

5.5 LoRA Fine-Tune untuk Domain B2B Indonesia

Fine-tune LoRA dilakukan pada dataset B2B Company X yang sudah anonimized: 800-1500 pasang (instruction, function_call) yang diekstrak dari log operasional 6 bulan terakhir. LoRA rank 16, alpha 32, dropout 0.05, target modules: q_proj, k_proj, v_proj, o_proj. Training: 3 epoch, lr 2e-4, batch size 4 (dengan gradient accumulation 4). Hardware: GPU cloud spot (RTX 4090 ~Rp 30rb/jam, total training ~6 jam = Rp 180rb one-time). Output: adapter file ~50MB yang di-merge saat runtime oleh llama.cpp. Evaluasi wajib: held-out 100 pasang untuk function call accuracy, threshold deploy ≥ 92%.

5.6 Inference Server: llama.cpp vs Ollama vs vLLM

Server	Use Case	Hardware	Notes
llama.cpp HTTP	Production on-prem	CPU only, 16GB	Paling frugal, native GGUF

Server	Use Case	Hardware	Notes
Ollama	Development lokal	CPU only, 16GB	Convenience API, model mgmt mudah
vLLM	Production scale	GPU 12GB+ (RTX 3060+)	Throughput 10x llama.cpp, butuh GPU
llama.cpp + GPU	Step-up on-prem	GPU 8GB+	Upgrade path tanpa rewrite

Tabel 5.1 — Pilihan inference server berdasarkan skenario dan hardware

Chapter 6 · ERP Module Design / Desain Modul ERP

6.1 Schema Core PostgreSQL

Schema ERP B2B disusun mengikuti pola DDD (Domain-Driven Design) dengan tabel inti: **companies** (tenant), **contacts** (customer/supplier), **products** (SKU, uom, price tiers), **inventory** (stok per warehouse), **sales_orders**, **purchase_orders**, **invoices**, **journal_entries**, **audit_log**. Setiap tabel memiliki kolom tenant_id (UUID, RLS), created_at, updated_at, created_by, updated_by, dan soft delete column deleted_at. Indexing: composite index pada (tenant_id, created_at) untuk semua tabel transaksional. Hermes hook dipasang di level API (tool call), bukan di level trigger database — agar audit trail tetap jelas dan tidak ada side-effect tersembunyi.

6.2 Hermes-Powered Features per Modul

Hermes bukan dipakai untuk semua operasi. Ia hanya dipanggil pada titik di mana input variance tinggi dan deterministic code akan kaku — misalnya parsing email RFQ customer (subject, body, attachment), atau summarizing 50 invoice menjadi laporan bulanan. Berikut tabel mapping modul ke Hermes hook dan value bisnis yang dihasilkan:

Modul	Key Tables	Hermes Hook	Business Value
Inventory	products, inventory, warehouses	Demand forecast, anomali stok	Out-of-stock turun ~40%
Sales Order	sales_orders, sales_order_items	Auto-quote dari RFQ email	Lead-to-quote 3 hari → 30 mnt
Purchase Order	purchase_orders, suppliers	Draft PO dari forecast	Purchasing time -60%
Invoicing	invoices, journal_entries	OCR invoice supplier, e-Faktur	Manual entry -83%
Lead Mgmt	leads, lead_scores, contacts	Scoring, routing, summary	Sales focus time +2x
HRIS-lite	employees, leave_requests	Approval validation, KPI	HR admin -50%
Reporting	(view semua modul)	NL → SQL & chart	Report time -97%

Tabel 6.1 — Mapping modul ERP, tabel inti, Hermes hook, dan business value

6.3 Audit Log & Row-Level Security Multi-Tenant

Audit log menyimpan setiap Hermes tool call dengan payload lengkap: timestamp, tenant_id, user_id, tool_name, input JSON, output JSON, latency ms, success/fail flag. Tujuannya: (a) debugging ketika Hermes memilih tool yang salah, (b) fine-tune dataset baru — audit log menjadi sumber pasangan (instruction, function_call) untuk LoRA iterasi kedua, (c) compliance — auditor dapat melihat siapa meminta apa kapan. RLS diaktifkan di setiap tabel: SET app.tenant_id = ? di level session, lalu policy PostgreSQL memfilter otomatis. Hermes juga di-inject tenant_id ke system prompt agar tidak salah ambil data saat tool call.

Chapter 7 · Website Profile B2B Design

7.1 Stack: Next.js 14 + Tailwind + shadcn/ui (Semua OSS)

Website profile B2B dibangun dengan Next.js 14 App Router (RSC default), Tailwind CSS untuk styling, dan shadcn/ui untuk komponen (semuanya open-source dan bebas komersial). Deployment target: Cloudflare Pages (free tier — unlimited static + 100.000 function invocations/hari) atau Vercel Hobby (free untuk tim kecil). Kedua opsi mendukung edge runtime sehingga latensi TTFB < 200ms di Indonesia via Singapore edge. Tidak ada vendor lock-in yang serius — bisa pindah hosting dalam < 1 hari kerja.

7.2 Struktur Halaman

Struktur halaman yang direkomendasikan untuk B2B: **Homepage** (value prop + 3 industri vertical utama + social proof), **Products/Services** (katalog dengan filter industri), **Company Profile** (tentang, tim, sertifikasi, sejarah), **Case Studies** (3-6 case study dengan struktur STAR: Situation, Task, Action, Result — angka konkret wajib), **Blog/CMS** (educational content untuk SEO B2B long-tail), **Contact/Lead Capture** (form multi-step dengan progressive profiling), **Customer Portal** (login area untuk existing customer — view order, download invoice, request support).

7.3 Hermes-Powered Features di Website

Empat fitur Hermes yang langsung menambah nilai: **(1) Chatbot B2B qualifier** — bukan generic chatbot, melainkan Hermes dengan tool set get_industry_info, create_lead, route_to_sales. Skenario: user bertanya "apakah produk Anda cocok untuk manufacturing makanan?" → Hermes panggil get_industry_info untuk konten relevan, lalu create_lead dengan metadata industri. **(2) Auto-content generator** untuk blog — Hermes draft artikel berdasarkan keyword research + outline editor review. Output: 1500-2000 kata draft, editor polish 30 menit. **(3) Dynamic meta-tag generator** untuk SEO B2B — Hermes generate title, meta description, OG tag per halaman berdasarkan konten + keyword target. **(4) Programmatic SEO** — generate halaman landing per industri × lokasi (misal "distribusi bahan kimia Jakarta") dengan konten unik yang Hermes tulis dari template + data ERP.

7.4 Lead Capture Form wired ke Hermes Scoring

Form lead capture multi-step: Step 1 (nama, perusahaan, email), Step 2 (industri, ukuran perusahaan, lokasi), Step 3 (use case, timeline, budget). Setiap step di-submit incremental ke backend — bukan tunggal akhir.

Hermes scoring berjalan di step terakhir, tetapi warm-up mulai step 1 dengan inferensi parsial. Skor > 70: webhook ke sales via Slack/email dalam < 30 detik. Skor 40-70: masuk nurture queue (email otomatis). Skor < 40: tetap direkam tapi tidak alert. SEMUA lead tetap masuk database — Hermes hanya memprioritaskan, tidak menolak. Ini menjaga net capture tetap tinggi sambil meningkatkan response time untuk lead berkualitas.

7.5 SEO B2B: Programmatic dengan Hermes

SEO B2B menang dari long-tail keyword industri-vertical-lokasi. Hermes dapat generate halaman landing unik per kombinasi (misal 5 industri × 10 kota = 50 halaman) dengan konten 800-1200 kata yang unik (bukan spun). Template: H1 value prop, 3 bagian kontent (industry context, our solution, case study link), CTA. Hermes mengisi konten dari dataset (industri profile, lokasi demographic, related case studies). Editor review 5 menit per halaman. Output: 50 halaman dalam 2 hari kerja vs 4 minggu manual writer. Hemat Rp 25-40 juta cost content writer. Bonus: konten tetap human-reviewed jadi aman dari Google Helpful Content penalty.

Chapter 8 · Integration Layer / Lapisan Integrasi

8.1 API Gateway: Hono on Cloudflare Workers (Free)

API gateway menggunakan Hono framework (lightweight, edge-optimized, TypeScript) dideploy ke Cloudflare Workers free tier. Workers free: 100.000 request/hari, cukup untuk skenario B2B Company X (estimasi 8.000-15.000 request/hari di peak). Keunggulan: cold start ~5ms (vs Lambda ~200ms), edge global (Singapore node dekat Indonesia), automatic DDoS protection, dan tidak perlu manage server. Untuk skenario overflow (viral content, campaign), bisa upgrade ke Workers Paid (USD 5/bulan untuk 10 juta request) — tetap sangat murah. Hono juga portable: bisa pindah ke Bun, Deno Deploy, atau Node.js biasa jika Cloudflare berubah kebijakan.

8.2 Webhook + Queue: Redis Upstash atau SQLite-based

Untuk async processing (lead scoring, report generation, invoice OCR batch), diperlukan queue. Dua opsi yang sesuai budget zero-cost: **(a) Upstash Redis free tier** — 10.000 command/hari, persistent, serverless REST API, ideal untuk queue ringan. **(b) SQLite-based queue** via Better Queue atau pg-boss (jika pakai Postgres) — zero additional service, embed di worker process, tetap reliable untuk throughput menengah. Untuk Company X direkomendasikan opsi (b) — pg-boss on Postgres — karena tidak menambah SaaS dependency dan tetap free. Migration ke Upstash hanya jika throughput melebihi kapasitas Postgres free tier.

8.3 Hermes Function Calling Bridge

Bridge antara request user dan Hermes inference adalah module TypeScript yang mengelola: (1) tool registry — daftar tool yang tersedia dengan schema validasi (zod), (2) prompt assembly — system prompt + tool schemas + user message, (3) inference call — POST ke Hermes server (llama.cpp HTTP di on-prem via Cloudflare Tunnel), (4) response parsing — ekstrak function_call tag, validasi parameter, (5) tool execution — call ke ERP API atau Hermes hook lain, (6) loop — jika Hermes minta info tambahan, loop kembali ke step (3), (7) rate limiting — 10 request/menit per tenant, queue jika exceed. Modul ini menjadi single source of truth untuk semua Hermes call — tidak ada code yang langsung panggil Hermes tanpa lewat bridge.

8.4 Data Flow: Sync vs Async via Queue

Alur sync: Website → API (Hono) → ERP DB → Hermes (untuk klasifikasi/scoring) → return ke user dalam < 3 detik. Alur async: Website → API → push job ke pg-boss queue → worker process (background) ambil job → call Hermes → update ERP → webhook ke sales. Sync dipakai untuk interaksi user-facing yang butuh response cepat. Async untuk job yang latency Hermes (15-40 detik) tidak boleh block user — seperti report generation, batch OCR, complex quote. Pemisahan ini menjaga UX tetap responsif sementara Hermes bekerja di background.

8.5 Security: API Key, Signed Webhook, RLS

Komponen	Tech Choice	Reason	Cost
API Gateway	Hono on CF Workers	Free tier, edge, cold start 5ms	Rp 0
Queue	pg-boss on Postgres	No new SaaS, embedded	Rp 0
Hermes Bridge	TypeScript module	Single source of truth	Rp 0
Tunnel	Cloudflare Tunnel	Expose on-prem Hermes gratis	Rp 0
Auth	Lucia + JWT + API key	OSS, no vendor lock-in	Rp 0
Monitoring	Better Stack free + Sentry	Error tracking + uptime	Rp 0

Tabel 8.1 — Komponen integration layer, pilihan teknologi, alasan, dan biaya bulanan

Security baseline: API key per tenant dengan rotation 90 hari, JWT untuk session user (15 menit access + 7 hari refresh), webhook signature HMAC-SHA256 agar Hermes callback tidak dapat di-spoof, dan RLS pada setiap query Postgres. Tidak ada API endpoint yang ter-expose tanpa autentikasi. Hermes pun tidak ter-expose ke public — ia hanya bisa dipanggil dari Workers via tunnel yang authenticated.

Chapter 9 · Tech Stack Recommendation / Rekomendasi Stack

9.1 Stack Final Berdasarkan Cost-Efficiency

Stack final yang direkomendasikan mengikuti prinsip **frugal tanpa mengorbankan kualitas**: setiap komponen open-source, gratis untuk skala Company X saat ini, dan punya upgrade path yang jelas jika traffic/use case berkembang. Tidak ada vendor lock-in yang serius — pindah dari Cloudflare ke Vercel atau dari Neon ke Supabase bisa dilakukan dalam 1-2 hari kerja. Berikut breakdown cost sheet per komponen dengan asumsi traffic normal (10-15rb request/hari, 100 leads/bulan, 50 invoice/bulan):

Komponen	Tech	Tier	Monthly (IDR)	Annual (IDR)
Website Hosting	Cloudflare Pages	Free	0	0

Komponen	Tech	Tier	Monthly (IDR)	Annual (IDR)
API Gateway	CF Workers	Free (100k/day)	0	0
Database	Neon Postgres	Free (0.5GB)	0	0
Hermes Inference	llama.cpp on-prem	Self-host	~150rb (listrik)	~1.8 jt
Tunnel	Cloudflare Tunnel	Free	0	0
Error Monitoring	Sentry free	Free (5k err)	0	0
Uptime Monitor	Better Stack free	Free (10 monitors)	0	0
Email Transaksi	Resend free	Free (3k/bulan)	0	0
Domain	.com / .id	n/a	~20rb	~240rb
Total			**~Rp 170rb**	**~Rp 2.04 jt**

Tabel 9.1 — Cost sheet komponen stack dengan total bulanan dan tahunan (IDR)

Dengan total operasional ~Rp 170rb/bulan (mayoritas biaya listrik on-prem Hermes dan domain), Company X mendapatkan ERP B2B + website profile + Hermes AI agent. Bandingkan dengan ERP SaaS komersial (misal SAP Business One, Oracle NetSuite) yang rata-rata Rp 4-15 juta/bulan untuk skala serupa. Saving tahunan: Rp 45-180 juta. Trade-off yang harus diterima: tim engineering harus manage infra sendiri (upgrade, backup, security) — tetapi dokumentasi + automation script akan diserahkan sebagai bagian dari handover, dan biaya engineering ini sudah ter-cover dalam scope project ini.

Chapter 10 · Implementation Roadmap / Roadmap Implementasi

Roadmap 6 bulan dibagi dalam 5 fase yang saling dependent tetapi dapat dieksekusi oleh tim kecil (1 developer + 1 AI engineer part-time). Setiap fase memiliki deliverable konkret yang dapat diukur, dan Hermes hook yang spesifik — agar Hermes tidak hanya dipasang di akhir, melainkan terlibat dari fase awal untuk validasi use case secara bertahap.

Phase	Timeline	Aktivitas Utama	Deliverable	Hermes Hook
1 — Foundation	Bulan 1	Audit, setup on-prem Hermes (Q4_K_M), Cloudflare Tunnel, repo init, schema Postgres	Hermes live via API, schema DDL, CI/CD	Baseline function call test
2 — Core ERP	Bulan 2-3	Inventory extend + Sales Order + PO modul, Hermes tool registry v1, RLS	3 modul production-ready, 8 tools	Auto-quote dari RFQ, PO draft
3 — Website	Bulan 4	Next.js 14 + shadcn/ui, halaman profile, lead form, blog CMS	Website live, 50 halaman SEO programmatic	Chatbot qualifier, lead scoring

Phase	Timeline	Aktivitas Utama	Deliverable	Hermes Hook
4 — Fine-Tune	Bulan 5	LoRA fine-tune dari audit log 4 bulan, A/B test base vs LoRA, hardening	LoRA adapter, accuracy >92%	Domain-specific Hermes B2B
5 — Hardening	Bulan 6	Monitoring, backup DR, security audit, documentation, handover training	Runbook, backup tested, training	Eval set v2, drift detection

Tabel 10.1 — Roadmap 5 fase dalam 6 bulan dengan deliverable dan Hermes hook per fase

Setelah fase 5 selesai, sistem siap handover ke tim internal Company X. Hermes LoRA adapter, audit log eval set, runbook, dan training material menjadi artifact yang dapat di-maintain oleh tim internal tanpa dependency pada tim engineering awal. Iterasi berikutnya (bulan 7-12) bisa fokus pada: ekspansi modul (CRM, manufacturing, warehouse management), Hermes-3-70B trial untuk task strategis, dan integrasi machine learning model custom untuk demand forecasting — tetap dengan prinsip frugal dan open-source.

Chapter 11 · Risk Analysis & Mitigation / Analisis Risiko

Setiap pilihan teknologi membawa risiko. Blueprint ini mengidentifikasi 6 risiko utama dengan severity, probability, dan mitigasi yang spesifik. Tidak ada risiko yang fatal — semuanya dapat dimitigasi dengan kombinasi engineering practice standar dan fallback plan yang sudah disiapkan sebelum build dimulai.

Risk	Severity	Prob.	Mitigation	Owner
Hardware limit → Hermes latency tinggi	Medium	High	Q4_K_M, batching, fallback ke 8B saat peak, upgrade path ke GPU seken	AI Engineer
Free-tier cloud rate limit	Low	Medium	Cache layer (KV), queue, upgrade ke Workers Paid ($5/bulan)	DevOps
Hermes hallucination pada tool call	High	Medium	JSON schema validation (zod), dry-run mode, human-in-the-loop untuk action destructive	AI Engineer
Data privacy B2B breach	High	Low	On-prem Hermes, encrypted at rest, RLS, audit log, no data ke vendor cloud	DevOps
LoRA overfitting pada dataset kecil	Medium	Medium	Eval set holdout 100 sampel, cross-validation, regularization, stop jika accuracy turun	AI Engineer
Vendor free-tier berubah kebijakan	Low	Low	Stack portable (Hono/Next.js/Postgres bisa pindah hosting < 1 hari)	DevOps

Tabel 11.1 — Risk register dengan severity, probability, mitigation, dan owner

Risiko terbesar yang perlu diwaspadai adalah **Hermes hallucination pada tool call** — severity tinggi karena bisa menyebabkan aksi yang salah di ERP (misal kirim invoice ke customer salah). Mitigasi utama bukan berharap Hermes akurat 100%, melainkan engineering: tool destructive (create/update/delete) harus melewati dry-run mode dulu, hasilnya di-preview ke user, baru di-execute setelah konfirmasi. Pattern ini disebut

human-in-the-loop dan sudah teruji di banyak production AI system. Audit log mencatat siapa yang konfirmasi sehingga traceability tetap jelas.

Chapter 12 · Kesimpulan & Next Steps / Conclusion

Blueprint ini menyimpulkan tiga hal kunci. **Pertama**, Hermes (NousResearch) adalah pilihan AI layer yang tepat untuk B2B Company X karena kombinasi gratis, privasi penuh, dan function call native — tiga kriteria yang sulit dipenuhi bersamaan oleh LLM lain. **Kedua**, dual-track approach (production optimize + greenfield build) memberi jalur yang aman: Track A menghormati investasi yang sudah ada, Track B membangun dengan AI-native architecture dari awal. **Ketiga**, stack zero-cost hybrid (cloud free-tier + on-prem Hermes via Cloudflare Tunnel) membuat total operasional bulanan hanya ~Rp 170rb — saving ~Rp 45-180 juta per tahun dibandingkan ERP SaaS komersial, dengan tetap mendapatkan kualitas model yang akurat.

12.1 Next Steps yang Dapat Dieksekusi Minggu Depan

- **Audit kickoff (Day 1-3)** — interview operator sales/inventory, list SaaS subscription aktif, capture log akses 1 minggu untuk baseline.
- **Hardware provisioning (Day 2-4)** — siapkan PC lama/i5-12gen RAM 16GB, install Ubuntu Server 22.04 LTS, Docker, llama.cpp. Download Hermes-2-Pro-8B GGUF Q4_K_M dari HuggingFace.
- **Hermes PoC (Day 5-7)** — jalankan Hermes HTTP server, test function call dengan 5 tool dummy (get_inventory, create_quote, list_customers, get_invoice, search_product). Ukur latency & accuracy.
- **Cloudflare Tunnel setup (Day 4-5 paralel)** — daftar Cloudflare free, konfigurasi tunnel ke on-prem Hermes HTTP server. Test invoke dari Workers.
- **Stakeholder alignment (Day 7)** — presentasi blueprint ini + hasil PoC ke decision maker Company X, dapatkan sign-off untuk phase 1, alokasi 2 FTE minimum 6 bulan.

12.2 Success Metrics yang Akan Dilacak

- **Cost per transaction** — target turun 75%+ dari baseline pasca Hermes integration.
- **Lead-to-quote time** — target dari 3 hari menjadi < 30 menit untuk lead dengan skor > 70.
- **Hermes function call accuracy** — target baseline 88% (pre-LoRA), pasca LoRA > 92%.
- **Operator hours saved** — target 18-25 jam/minggu (di-redirect ke task higher-value).
- **System uptime** — target 99.5% (Cloudflare + on-prem Hermes, 43.8 jam downtime/tahun max).

12.3 Catatan Akhir

Blueprint ini bukan dokumen statis. Ia akan di-revisi setelah fase 1 selesai berdasarkan temuan audit dan PoC, dengan asumsi yang diuji dan angka yang di-verifikasi. Tim engineering tetap berkomitmen pada prinsip frugal — setiap pengeluaran harus terukur manfaatnya, setiap komponen harus punya fallback, dan setiap Hermes hook harus bisa di-rollback tanpa downtime. Dengan discipline ini, dual-track Hermes-powered ERP dan website B2B Company X akan menghasilkan model operasional yang dapat menjadi referensi untuk B2B Indonesia secara lebih luas.